README — Proyecto Integrador Módulo 3

Documentación del proceso: limpieza, modelo relacional, dashboard y seguridad de datos

1. Contexto del proyecto

TechCore es una cadena de tiendas minoristas de tecnología con operación en varias ciudades de Colombia. DataVision Analytics fue contratada para centralizar y depurar la información de ventas, construir un modelo relacional confiable y desarrollar un dashboard interactivo en Power BI que permita extraer conclusiones estratégicas de negocio.

El proyecto se dividió en 4 etapas (Avances 1 a 4), cada una con un entregable propio, descritas a continuación.

2. Avance 1 — Limpieza y transformación (Power Query)

Se cargó el archivo de ventas original (ventas.csv, 30.307 filas) en Power BI y se aplicaron transformaciones en Power Query:

- Renombrado y estandarización de columnas.
- Corrección de tipos de datos (fechas, números, texto).
- Normalización de texto en ciudades y marcas (mayúsculas/minúsculas, acentos, variantes de escritura).
- Reemplazo de valores nulos en productos 2 y 3 por "No Aplica" / 0, dado que no todas las ventas incluyen 3 productos.
- Eliminación de 307 filas duplicadas exactas (mismo registro repetido íntegramente).

Resultado: ventasTransformed.csv con 30.000 filas, exportado para continuar el proceso en Python (Avance 2).

3. Avance 2 — Modelo relacional (Python + pandas)

A partir del dataset limpio se identificaron 7 entidades y se construyó el modelo relacional en un notebook de Jupyter (Avance_2_Modelo_Relacional.ipynb):

- Ciudades, Sucursales, Vendedores, Clientes, Productos, Facturas y DetalleFacturas.
- Se definieron claves primarias (ID autonumérico por tabla) y foráneas entre tablas relacionadas.
- Se hizo un unpivot de las columnas de producto 1/2/3 (formato ancho) a filas individuales en DetalleFacturas (formato largo).
- Se validó la integridad referencial de las 7 tablas: sin registros huérfanos en ninguna relación.

Hallazgos de calidad de datos (Avance 2)

Durante la construcción del modelo se detectaron y corrigieron tres inconsistencias no resueltas en el Avance 1:

- Typo de marca: "Razer" aparecía también como "Razor" en 4 modelos — se normalizó a "Razer".
- Precio unitario inflado: en líneas con Cantidad 10 o 20, el precio unitario venía multiplicado x10 por error (afectaba ~30.000 de 60.059 líneas). Se recalculó como Subtotal / Cantidad.
- La columna TotalVenta original no reconciliaba con la suma del detalle de la factura en ningún registro (0 de 30.000). Se conservó como TotalVentaOriginal (trazabilidad) y se agregó TotalVentaCalculado como el valor confiable usado en el dashboard.

El modelo final se exportó a modeloVentas.xlsx, con una hoja por tabla, lista para importar en Power BI.

4. Avance 3 — Dashboard interactivo (Power BI)

Se importó modeloVentas.xlsx en Power BI Desktop y se construyeron medidas DAX y visualizaciones:

- Medidas: VentasTotales, TicketPromedio, CantidadFacturas, ProductosVendidos, %ParticipacionCiudad.
- Columnas auxiliares: NombreCiudad (en Sucursales, vía RELATED), RangoEdad (en Clientes), y tabla DimFecha para la jerarquía Año/Mes/Día.
- Visualizaciones: 4 tarjetas KPI, mapa geográfico por ciudad, gráfico de barras de ventas por marca, línea de evolución temporal, dona de métodos de pago, tabla de productos, y segmentadores de ciudad/sucursal/marca/fecha.
- Diseño visual propio en paleta carbón (#36454F) y turquesa (#00A896), con encabezado, tarjetas con íconos y bordes suaves.

5. Avance 4 — Seguridad a nivel de fila (RLS) — extra credit

Se implementó un esquema de Row-Level Security con 3 roles jerárquicos:

- Gerente Nacional: acceso completo a todas las ciudades y sucursales (sin filtro).
- Gerente Regional: ve únicamente los datos de su ciudad asociada.
- Gerente Sucursal: ve únicamente los datos de su sucursal específica.

Se creó una tabla Usuarios simulada (11 usuarios: 1 nacional, 4 regionales, 6 de sucursal) con Nombre, Email, Rol, Ciudad y Sucursal asociada. Las reglas de cada rol usan LOOKUPVALUE() sobre USERPRINCIPALNAME() para filtrar dinámicamente las tablas Ciudades o Sucursales según el email del usuario que inicia sesión, propagando el filtro en cascada hacia Facturas y DetalleFacturas.

6. Resultados principales

$2,57 billones	$85,74 mill.	30.000	495.597
Ventas Totales	Ticket Promedio	Facturas	Productos Vendidos

- Lenovo es la marca líder en ventas ($656.165.600.000), seguida de HP y Dell.
- Medellín es la ciudad con mayores ventas ($1,15 billones), por delante de Bogotá.
- La tarjeta de crédito es el método de pago dominante (40,04% de los ingresos).
- Las ventas anuales son estables (entre $228.000 M y $241.000 M) desde 2015 hasta 2024; la aparente caída en 2025 se debe a que el dataset corta en septiembre de ese año (año incompleto), no a una tendencia real de negocio.

7. Archivos entregables

- ventasTransformed.csv — dataset limpio (Avance 1)
- Avance_2_Modelo_Relacional.ipynb — notebook con el modelo relacional y validaciones (Avance 2)
- modeloVentas.xlsx — 7 tablas del modelo + tabla Usuarios (Avance 2 y 4)
- Avance_3_Dashboard_PowerBI.pbix — dashboard interactivo (Avance 3)
- README.pdf — este documento
- Conclusiones_Recomendaciones.pdf — insights de negocio y propuestas de mejora